

WYDZIAŁ PODSTAWOWYCH PROBLEMÓW TECHNIKI
POLITECHNIKA WROCŁAWSKA

EWOLUCYJNY ALGORYTM DLA NIELINIOWEGO ZADANIA TRANSPORTOWEGO

PIOTR BEREZOWSKI
NR INDEKSU: 236749

Praca inżynierska napisana
pod kierunkiem
dr hab. Pawła Zielińskiego



Politechnika
Wrocławska

WROCŁAW 2019

Spis treści

| | | |
|----------|--------------------------------------------------------|-----------|
| 1 | Wstęp | 1 |
| 2 | Analiza problemu | 3 |
| 2.1 | Zadanie transportowe | 3 |
| 2.1.1 | Wersja liniowa | 4 |
| 2.1.2 | Wersja nieliniowa | 4 |
| 2.2 | Klasyczne rozwiązania | 4 |
| 2.3 | Algorytmy metaheurystyczne | 4 |
| 2.3.1 | Algorytmy ewolucyjne | 4 |
| 3 | Równoległa implementacja algorytmu ewolucyjnego | 7 |
| 3.1 | Użyte technologie | 7 |
| 3.2 | Reprezentacja chromosomu | 7 |
| 3.3 | Inicjalizacja chromosomu | 8 |
| 3.4 | Operator krzyżowania | 8 |
| 3.5 | Operator mutacji | 8 |
| 3.6 | Funkcje oceny | 9 |
| 3.7 | Metoda selekcji | 9 |
| 3.8 | Wersja równoległa | 9 |
| 3.9 | Pliki konfiguracyjne | 10 |
| 4 | Wyniki eksperymentalne | 13 |
| 4.1 | Model klasyczny algorytmu genetycznego | 13 |
| 4.2 | Model wyspowy algorytmu genetycznego | 13 |
| 5 | Podsumowanie | 15 |
| | Bibliografia | 17 |
| A | Zawartość płyty CD | 19 |

Wstep



Analiza problemu

2.1 Zadanie transportowe

Zadanie transportowe należy do grupy zadań optymalizacyjnych z ograniczeniami. Rozwiązując je staramy się przy użyciu n punktów nadania zaspokoić zapotrzebowanie m punktów odbioru w taki sposób, aby całkowity koszt transportu był minimalny. Zadanie wymaga określenia ilości towaru znajdującej się w każdym z punktów nadania, oraz zapotrzebowania na towar w każdym z punktów odbioru. Dodatkowo musimy określić koszt transportu pomiędzy każdym punktem nadania i każdym punktem odbioru. Klasyczne zadanie transportowe ogranicza się do transportu tylko jednego towaru, dzięki czemu punkty odbioru mogą być zaopatrywane przez jeden lub więcej punktów nadania.

Zadanie transportowe nazywamy zbilansowanym, jeśli całkowita podaż towaru jest równa całkowitemu popytowi. W przeciwnym wypadku zadanie jest niezbilansowane. Rozwiązywanie zadania niezbilansowanego polega na sprowadzeniu go do zadania zbilansowanego, poprzez dodanie fikcyjnego dostawcy (w przypadku większego popytu), lub fikcyjnego odbiorcy (w przypadku większej podaży). Wartość kosztu dostawy między fikcyjnym dostawcą a odbiorcami, lub między dostawcami a fikcyjnym odbiorcą najczęściej ustalany jest jako zerowy.

Założmy, że mamy n punktów nadania i m punktów odbioru. Początkowa ilość towaru w i -tym punkcie nadania jest równa $supply(i)$, a początkowe zapotrzebowanie w j -tym punkcie odbioru jest równe $demand(j)$. Jeśli x_{ij} jest ilością towaru dostarczanego przez i -ty punkt nadania do j -tego punktu odbioru, to zbilansowane zadanie transportowe możemy zdefiniować w następujący sposób:

$$\min \sum_{i=1}^n \sum_{j=1}^m f_{ij}(x_{ij})$$

Przy spełnionych ograniczeniach:

$$\sum_{j=1}^m x_{ij} = supply(i), \text{ dla } i = 1, 2, \dots, n$$

$$\sum_{i=1}^n x_{ij} = demand(j), \text{ dla } j = 1, 2, \dots, m$$

$$x_{ij} \geq 0, \text{ dla } i = 1, 2, \dots, n \text{ i } j = 1, 2, \dots, m$$

Pierwszy zestaw ograniczeń mówi o tym, że całkowita ilość towaru transportowana z pojedynczego punktu nadania musi być równa jego początkowej ilości znajdującej się w tym punkcie. Z kolei drugi zestaw mówi o tym, że całkowita ilość towaru transportowana do pojedynczego punktu odbioru musi być równa jego początkowemu zapotrzebowaniu. W przypadku zadania niezbilansowanego równości w dwóch pierwszych zestawach ograniczeń należy zmienić na odpowiednie nierówności. Zadanie jest liniowe, jeśli koszt transportu między punktami nadania i odbioru jest wprost proporcjonalny do ilości transportowanego towaru, tzn. jeśli $f_{ij}(x_{ij}) = cost_{ij}x_{ij}$, gdzie $cost_{ij}$ jest jednostkowym kosztem transportu między i -tym punktem nadania, a j -tym punktem odbioru.



2.1.1 Wersja liniowa

Zadanie transportowe w wersji liniowej należy do problemów programowania liniowego, a więc można rozwiązać je przy pomocy algorytmu sympleks.

[...*TODO*...]

2.1.2 Wersja nieliniowa

O ile liniowa wersja zadania jest stosunkowo łatwa w rozwiązaniu, o tyle dla wersji nieliniowej nie ma ogólnej metody rozwiązywania. Należy ono do problemów z kategorii NP-trudnych [TODO - znaleźć publikację]. Do jego rozwiązania używa się różnych algorytmów wyznaczających rozwiązania przybliżone, takich jak algorytmy metaheurystyczne.

2.2 Klasyczne rozwiązania

2.3 Algorytmy metaheurystyczne

Algorytmy metaheurystyczne znajdują zastosowanie szczególnie przy rozwiązywaniu nieliniowego zadania transportowego, ponieważ w tym przypadku nie są znane algorytmy, które wyznaczają dokładne rozwiązanie w akceptowalnym czasie.

2.3.1 Algorytmy ewolucyjne

Algorytmy ewolucyjne stanowią podzbiór algorytmów metaheurystycznych. Sposób ich działania jest inspirowany przez zjawisko ewolucji występujące w naturze. Na początku działania algorytmu generowana jest w sposób losowy populacja startowa. Procedurę generowania pojedynczego osobnika lub całej populacji nazywać będziemy **inicjalizacją**. Następnie na przestrzeni pokoleń(iteracji algorytmu) populacja ewoluuje generując coraz lepsze rozwiązania. W każdej iteracji pewna część osobników zostaje wybrana do reprodukcji. Procedurę wyboru rodziców do reprodukcji nazywać będziemy **selekcją**. Wybrane osobniki krzyżujemy między sobą, tworząc w ten sposób nowe, posiadające cechy wybranych wcześniej rodziców. Następnie losowo wybrane osobniki ulegają mutacji. Ostatecznie z otrzymanych osobników tworzona jest nowa populacja, która będzie stanowić bazę dla kolejnej iteracji algorytmu. Algorytm kończy działanie w momencie kiedy zostanie spełniony warunek końcowy, którym może być np. wygenerowanie wystarczająco dobrego rozwiązania lub przejście określonej liczby iteracji.

Pseudokod 2.1: Ogólny schemat działania algorytmu ewolucyjnego

```

1  $P(t)$ : Populacja w  $t$ -tej iteracji algorytmu;
2  $O(t)$ : Populacja dzieci w  $t$ -tej iteracji algorytmu;
3  $t \leftarrow 0$ ;
4 inicjalizacja  $P(t)$ ;
5 while Warunek końcowy nie został spełniony do
6    $parents \leftarrow$  selekcja z  $P(t)$ ;
7    $O(t+1) \leftarrow$  zastosuj operator krzyżowania na  $parents$ ;
8    $O(t+1) \leftarrow$  zastosuj operator mutacji na  $O(t+1)$ ;
9    $P(t+1) \leftarrow$  wybierz osobniki do następnej generacji z  $O(t+1)$ ;
10   $t \leftarrow t+1$ ;
11 return najlepszy osobnik z  $P(t)$ ;
```

[TODO: Dodać algorytm w wersji graficznej]

Projektowanie algorytmu ewolucyjnego możemy podzielić na kilka oddzielnych części, są to:

- Reprezentacja - określa sposób zakodowania rozwiązania w chromosomie. Wybór reprezentacji chromosomu jest bardzo ważnym etapem projektowania algorytmu. Odpowiednia reprezentacja może w znacznym stopniu wpłynąć na szybkość i jakość rozwiązań znajdowanych przez algorytm, ponieważ to ona w dużej mierze określa sposób w jaki przeszukiwana będzie przestrzeń rozwiązań zadania. Jako reprezentacje bardzo często stosowane są wektory lub macierze genów, gdzie gen może być pojedynczą liczbą całkowitą lub rzeczywistą. Oczywiście jako sposób reprezentacji rozwiązania możemy wybrać dowolną strukturę danych, należy jednak pamiętać, że zdefiniowane później operacje mutacji i krzyżowania muszą być dostosowane do wybranej struktury.
- Funkcja oceny - określa stopień przystosowania danego osobnika. Bardzo często funkcja oceny jest równoważna funkcji celu, którą nasz algorytm ma minimalizować/maksymalizować, nie jest to jednak regułą.
- Operator krzyżowania - jest jednym z operatorów używanych do generowania kolejnego pokolenia w algorytmach ewolucyjnych. Z założenia przyjmuje on jako argumenty dwa lub więcej rozwiązań (rodziców) i generuje na ich podstawie nowe (dzieci), które łączą w sobie cechy rodziców. [TODO: przykład]
- Operator mutacji - jest drugim z operatorów używanych do generowania następnych pokoleń w algorytmach ewolucyjnych. Jego celem jest poszerzenie obszaru przeszukiwanych rozwiązań. Ten operator powinien wprowadzać minimalną zmianę w rozwiązaniu, co zapobiega zbyt szybkiej zbieżności algorytmu i pozwala na wprowadzenie dodatkowej różnorodności w populacji. Należy pamiętać o tym, że wprowadzana zmiana nie może być za duża, bo może to prowadzić do odwrotnego rezultatu, czyli zamiast różnicować rozwiązania nasz operator może je niszczyć. [TODO: przykład]
- Selekcja - określa sposób wyboru rodziców na których użyjemy operatora krzyżowania. Istnieje wiele opisanych metod selekcji [3] takich jak np. metoda koła ruletki czy metoda rankingowa. Przy tworzeniu procedury selekcji należy pamiętać o tym, że rozwiązania lepiej przystosowane powinny mieć większe szanse na zostanie rodzicami dla kolejnego pokolenia. Zapewnia to większe szanse na wygenerowanie lepszych dzieci do następnej generacji. [TODO: przykład]
- Wybór następnego pokolenia - ostateczny krok algorytmu, w którym wybieramy które osobniki wejdą w skład populacji początkowej w kolejnej iteracji algorytmu. Podstawową składową tej populacji powinny być oczywiście osobniki wygenerowane za pomocą krzyżowania. Często stosowaną praktyką jest również przepisywanie części najlepszych rozwiązań oraz kilku losowo wybranych z poprzedniego pokolenia.



Równoległa implementacja algorytmu ewolucyjnego

3.1 Użyte technologie

Do implementacji algorytmu zastosowano język Julia[1] w wersji 1.3. Julia jest stosunkowo nowym językiem programowania. Został on zaprojektowany z myślą o zastosowaniach w obliczeniach numerycznych. Łączy on w sobie zalety języków niskopoziomowych i wysokopoziomowych takie jak szybkość i czytelność kodu. Testy pokazują, że program napisany w Julii może być równie szybki, jak program napisany w C[2].

Ostatnie aktualizacje w znaczącym stopniu rozwinęły wsparcie języka dla obliczeń równoległych. W tym momencie Julia oferuje wsparcie dla równoległości na poziomie wątków jak i procesów, co dodatkowo wpłynęło na wybór tego właśnie języka.

3.2 Reprezentacja chromosomu

W opisywanej implementacji jako reprezentację rozwiązania przyjęto macierz:

$$V = (v_{ij}), \text{ gdzie } 1 \leq i \leq \text{length}(\text{demand}) \wedge 1 \leq j \leq \text{length}(\text{supply})$$

Rozwiązanie jest zakodowane w taki sposób, że komórka macierzy o indeksie $[i, j]$ określa ilość transportowanego towaru między i -tym punktem nadania i j -tym punktem odbioru. Jest to jedna z najbardziej naturalnych reprezentacji rozwiązania dla zadania transportowego.

| i \ j | 10.0 | 7.0 | 5.0 | 13.0 | 12.0 |
|-------|------|-----|-----|------|------|
| 12.0 | 0.0 | 7.0 | 5.0 | 0.0 | 0.0 |
| 10.0 | 5.0 | 0.0 | 0.0 | 0.0 | 5.0 |
| 3.0 | 3.0 | 0.0 | 0.0 | 0.0 | 0.0 |
| 10.0 | 0.0 | 0.0 | 0.0 | 3.0 | 7.0 |
| 12.0 | 2.0 | 0.0 | 0.0 | 10.0 | 0.0 |

Tablica 3.1: Przykładowe rozwiązanie(pierwszy wiersz - wektor punktów odbioru, pierwsza kolumna - wektor punktów nadania).

Aby ograniczenia zadania zostały zachowane macierz rozwiązania musi spełniać następujące warunki:

$$\sum_{j=1}^m v_{ij} = \text{supply}[i], \text{ dla } i = 1, 2, \dots, n, \text{ gdzie } n = \text{length}(\text{demand})$$

$$\sum_{i=1}^n v_{ij} = \text{demand}[j], \text{ dla } j = 1, 2, \dots, m, \text{ gdzie } m = \text{length}(\text{supply})$$

$$v_{ij} \geq 0, \text{ dla } i = 1, 2, \dots, n \text{ i } j = 1, 2, \dots, m$$



3.3 Inicjalizacja chromosomu

[TODO: Opis] [TODO: Przykład]

3.4 Operator krzyżowania

Operator krzyżowania został zdefiniowany jako kombinacja wypukła dwóch rodziców.

Data: P_1, P_2 - rodzice wybrani do krzyżowania

Result: O_1, O_2 - otrzymane dzieci

```

1  $c_1 \leftarrow rand(0, \dots, 1)$ ;
2  $c_2 \leftarrow 1.0 - c_1$ ;
3  $O_1 \leftarrow c_1 * P_1 + c_2 * P_2$ ;
4  $O_2 \leftarrow c_2 * P_1 + c_1 * P_2$ ;
5 return ( $O_1, O_2$ );
```

Zdefiniowany tak operator krzyżowania nie narusza ograniczeń zadania, ponieważ przestrzeń rozwiązań jest wypukła. Wynika z tego, że jeśli rodzice spełniali ograniczenia, to otrzymane w ten sposób dzieci również muszą spełniać ograniczenia.

[TODO: Dodać przykład zastosowania operatora]

3.5 Operator mutacji

Operator mutacji opiera się na modyfikacji rozwiązania poprzez wybranie z niego podmacierzy i jej ponowną inicjalizację. Załóżmy, że mamy n punktów nadania i m punktów odbioru. Wybierzmy jako kandydata do mutacji macierz $V = (v_{ij})$, gdzie $1 \leq i \leq n$ i $1 \leq j \leq m$. Podmacierz $W = w_{ij}$ jest tworzona w następujący sposób:

- Losujemy podzbiór k indeksów $\{i_1, \dots, i_k\}$ ze zbioru $\{1, \dots, n\}$ oraz podzbiór l indeksów $\{j_1, \dots, j_l\}$ ze zbioru $\{1, \dots, m\}$, $2 \leq k \leq n$ i $2 \leq l \leq m$.
- Tworzymy podmacierz W składającą się z takich elementów macierzy V , które zostały wylosowane, tzn. element $v_{ij} \in V$ zostaje włączony do podmacierzy W tylko jeśli $i \in \{i_1, \dots, i_k\}$ oraz $j \in \{j_1, \dots, j_l\}$.

Dla stworzonej macierzy W tworzymy nowe wektory $demand_W$ i $supply_W$ w następujący sposób:

$$demand_W[i] = \sum_{j \in \{j_1, \dots, j_l\}} v_{ij}, \text{ dla } 1 \leq i \leq k$$

$$supply_W[j] = \sum_{i \in \{i_1, \dots, i_k\}} v_{ij}, \text{ dla } 1 \leq j \leq l$$

Następnie na nowo inicjalizujemy podmacierz W macierzy V używając stworzonych wektorów $demand_W$ oraz $supply_W$ do określenia popytu i podaży w wybranych punktach nadania i odbioru. Po zakończeniu inicjalizacji przepisujemy wartości z podmacierzy W z powrotem do macierzy V .

Zdefiniowano dwa operatory mutacji różniące się jedynie procedurą inicjalizacji. W pierwszym używamy tej samej procedury, którą inicjalizujemy nowe chromosomy podczas generowania populacji początkowej. Druga jest modyfikacją tej procedury. Modyfikacja polega na tym, że zamiast wybierać jako wartość pola $val = \min(demand[i], supply[j])$ wybieramy liczbę z zakresu $[0, val]$. Zmiana ta powoduje, że otrzymana macierz może naruszać ograniczenia zadania, dlatego po wstępnym wyznaczeniu wartości naprawiamy rozwiązanie poprzez zrobienie wymaganych dodawań w taki sposób, żeby rozwiązanie spełniało ograniczenia.

[TODO: Pseudokod] [TODO: Przykład]

```
Data:  $V$  - osobnik wybrany do mutacji wielkości  $n \times m$ ,  $k, l$  - wielkość podmacierzy
Result:  $V$  - osobnik po mutacji
1  $demand\_idx \leftarrow$  wylosuj podzbiór długości  $k$  ze zbioru  $\{1, \dots, n\}$ ;
2  $supply\_idx \leftarrow$  wylosuj podzbiór długości  $l$  ze zbioru  $\{1, \dots, m\}$ ;
3  $W \leftarrow \text{zeros}(k, l)$  ; /* generujemy macierz zerową rozmiaru  $k \times l$  */
4 for  $i \in \{1, \dots, k\}$  do
5   for  $j \in \{1, \dots, l\}$  do
6      $W[i, j] \leftarrow V[demand\_idx[i], supply\_idx[j]]$ ;
7  $demand\_vec \leftarrow \text{zeros}(k)$  ; /* generujemy wektor zerowy długości  $k$  */
8  $supply\_vec \leftarrow \text{zeros}(l)$  ; /* generujemy wektor zerowy długości  $l$  */
9 for  $i \in demand\_idx$  do
10    $demand\_vec[i] \leftarrow \sum_{j \in supply\_idx} V[i, j]$ ;
11 for  $j \in supply\_idx$  do
12    $supply\_vec[j] \leftarrow \sum_{i \in demand\_idx} V[i, j]$ ;
13  $W \leftarrow \text{inicjalizacja}(W, demand\_vec, supply\_vec)$ ;
14 for  $i \in \{1, \dots, k\}$  do
15   for  $j \in \{1, \dots, l\}$  do
16      $V[demand\_idx[i], supply\_idx[j]] \leftarrow W[i, j]$ ;
17 return  $V$ 
```

3.6 Funkcje oceny

3.7 Metoda selekcji

W algorytmie zastosowano standardową metodę selekcji - metodę koła ruletki. W tej metodzie lepiej przystosowane osobniki mają odpowiednio większe szanse na to, że zostaną wybrane do puli rodziców dla następnej generacji. Na początku obliczana jest suma kumulatywna dla całego pokolenia. Następnie otrzymane wartości skalujemy tak, aby znajdowały się w przedziale $[0, 1]$. W ten sposób przedział $[0, 1]$ zostaje podzielony na mniejsze, które odpowiadają pojedynczym osobnikom z populacji. Następnie generujemy losową liczbę z tego przedziału. Do zbioru rodziców dodawany jest osobnik, w którego przedziale znajduje się wylosowana liczba. Warto zauważyć że tak zaprojektowana selekcja pozwala na to, że jeden osobnik zostanie wybrany kilkakrotnie na rodzica. [TODO: obrazek ilustrujący algorytm]

3.8 Wersja równoległa

Algorytm może działać w dwóch trybach:

- Klasycznym
- Wyspowym

Model klasyczny nie różni się wiele od standardowego algorytmu ewolucyjnego. Mamy tutaj standardowo jedną populację, która ewoluuje przez określoną na starcie liczbę pokoleń. Wszystkie dostępne parametry algorytmu oraz ich dopuszczalne wartości opisane są w dalszej części pracy, w sekcji *Pliki konfiguracyjne*.

W modelu klasycznym zrównoleglenie odbywa się na poziomie pojedynczej iteracji. Ewolucje populacji możemy podzielić tutaj na dwie części:

- Krzyżowanie - w tej części między wątki rozdzielani są rodzice wybrani do krzyżowania. Następnie każdy z wątków generuje swoją część dzieci, następnie z określonym prawdopodobieństwem stostuje na



dzieciach operator mutacji i ostatecznie oblicza dla nich wartość funkcji oceny. Dzieci są dodawane do kolejnej populacji.

- Dopelnienie populacji - w tej części do kolejnej populacji przepisywana jest część najlepszych rozwiązań oraz losowo wybranych osobników z poprzedniej populacji. Następnie te dodane osobniki są poddawane mutacji i obliczana jest dla nich funkcja oceny.

Model wyspowy różni się od klasycznego podejścia tym, że całkowita populacja jest tutaj rozdzielana na kilka mniejszych. Następnie każda z populacji częściowych ewoluuje niezależnie od innych przez określoną liczbę pokoleń. Po zakończeniu tego procesu wszystkie częściowe populacje są na nowo łączone w jedną. Następnie najlepsze rozwiązywanie jest zapisywane, a populacja zostaje na nowo podzielona na kilka mniejszych i cały proces się powtarza, do momentu w którym ilość generacji przekroczy określoną na początku liczbę. Na końcu najlepsze rozwiązanie jest zwracane.

W tym modelu zrównoleglenie obliczeń polega na tym, że przy każdym podziale populacji jeden wątek zarządza pojedynczą częścią populacji. Model ten skaluje się lepiej niż model klasyczny ze względu na to że podzadania przydzielane wątkom są większe. Minusem jest tutaj to, że populacja musi być odpowiednio duża, żeby jej podział na mniejsze części się sprawdził. [TODO: Algorytm w wersji graficznej]

W tym momencie każda z częściowych populacji w modelu wyspowym posiada takie same parametry. [...]

3.9 Pliki konfiguracyjne

Dodatkowo do algorytmu został dodany moduł obsługi plików konfiguracyjnych. Używają one formatu JSON. Moduł pozwala na zapisywanie i wczytywanie całej konfiguracji algorytmu, w skład której wchodzi wektory popytu i podaży, macierz kosztu, oraz wszystkie parametry programu. Definicja poszczególnych parametrów:

- `populationSize` - rozmiar całkowitej populacji. Powinien być dodatnią liczbą całkowitą.
- `eliteProc` - ułamek najlepszych rozwiązań, które zostają przepisane do następnego pokolenia. Wartość powinna znajdować się w przedziale $[0, 1]$. Testy pokazują, że najlepsze rozwiązania są generowane dla wartości parametru w przedziale $[0.1, 0.3]$.
- `mutationProb` - prawdopodobieństwo mutacji. Przyjmuje wartość z zakresu $[0, 1]$. Warto pamiętać o tym, że zalecane prawdopodobieństwo mutacji nie powinno przekraczać kilkunastu procent.
- `mutationRate` - wielkość mutacji, określa stosunek rozmiaru podmacierzy, wybieranej do ponownej inicjalizacji podczas mutacji, do macierzy rozwiązania. Przyjmuje wartości z zakresu $[0, 1]$. Tak jak w przypadku prawdopodobieństwa mutacji, jej wielkość nie powinna przekraczać kilkunastu procent, ponieważ zbyt duża mutacja może niszczyć znalezione rozwiązania.
- `crossoverProb` - prawdopodobieństwo krzyżowania. Przyjmuje wartości z przedziału $[0, 1]$. Zaleca się ustawianie wartości z przedziału $[0.5, 0.9]$. Należy pamiętać o tym, że suma parametrów `eliteProc` i `crossoverProb` nie może być większa niż 1.
- `mode` - tryb w jakim ma działać algorytm. Przyjmuje wartości "regular" (w przypadku wyboru klasycznego modelu) lub "island" (w przypadku modelu wyspowego).
- `numberOfSeparateGenerations` - liczba naturalna określająca ilość iteracji jakie wykona algorytm pomiędzy rozdzieleniem populacji na mniejsze części, a ponownym jej scaleniem. Dla wyboru modelu klasycznego należy ustawić wartość parametru na 1.

Dodatkowo w pliku konfiguracyjnym określamy wektor popytu, podaży i macierz kosztów:

- `demand` - wektor popytu. Przyjmuje jako wartość listę elementów, które składają się z dwóch pól - "i", które określa indeks wektora i "val", które określa wartość wektora w miejscu i - `demand[i] = val`.

- `supply` - wektor podaży. Przyjmuje jako wartość listę elementów, o polach takich samych jak w przypadku wektora popytu. Pojedynczy element opisuje pole wektora $supply[i] = val$.
- `costMatrix` - macierz kosztu, która może być wykorzystywana w funkcji celu. Przyjmuje jako wartość listę elementów, które składają się z trzech pól: `ś`- określa indeks odpowiadający indeksowi wektora podaży, `d`- określa indeks odpowiadający indeksowi wektora popytu, oraz `val`- określa wartość macierzy w polu o podanych indeksach $costMatrix[d, s] = val$.

Przykładowy plik konfiguracyjny:

[TODO: dodać przykładowy plik]



Wyniki eksperymentalne

4.1 Model klasyczny algorytmu genetycznego

4.2 Model wyspowy algorytmu genetycznego



Podsumowanie

W tym rozdziale znajdzie się podsumowanie pracy.



Bibliografia

- [1] S. K. Jeff Bezanson, Alan Edelman, V. B. Shah. Julia: A fresh approach to numerical computing. *SIAM Review*, 59:65–98, 2017.
- [2] V. B. S. Jeff Bezanson, Stefan Karpinski, A. Edelman. Julia: A fast dynamic language for technical computing. *ArXiv:1209.5145*, September 2012.
- [3] N. Saini. Review of selection methods in genetic algorithms. *International Journal of Engineering and Computer Science*, 6(12):22261–22263, Dec. 2017.



Zawartość płyty CD

W tym rozdziale należy krótko omówić zawartość dołączonej płyty CD.

